

UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO
UNIDADE ACADÊMICA DO CABO DE SANTO AGOSTINHO – UACSA
CAMPUS DAS ENGENHARIAS
CURSO DE ENGENHARIA ELETRÔNICA

IALISSON ROQUE DA SILVA

GERENCIAMENTO INTELIGENTE DE UM SISTEMA DE PRODUÇÃO

Aplicação de MDP e Aprendizado por Reforço à manutenção baseada em degradação

Cabo de Santo Agostinho – PE

2026

RESUMO

Este trabalho apresenta um modelo de gerenciamento inteligente de manutenção baseado em Processos de Decisão de Markov (MDP) e Aprendizado por Reforço. Como não foi identificado um conjunto público de linha de produção contendo trajetórias completas de degradação, ações de manutenção e falhas com granularidade adequada, foi utilizado o conjunto C-MAPSS, disponibilizado pelo NASA Prognostics Center of Excellence. Os sinais de sensores foram empregados como fonte da dinâmica de degradação, sem transferir para o problema de produção a física específica do motor turbofan. Um Health Index foi construído a partir de sensores selecionados por associação monotônica com a vida útil remanescente e redução dimensional por PCA. O índice foi discretizado em quatro estados de saúde e as transições naturais foram estimadas a partir das trajetórias de treinamento. Sobre esse ambiente foram comparadas uma política simples baseada em regras, Value Iteration e Q-Learning. Nos quatro conjuntos FD001–FD004, Value Iteration e Q-Learning convergiram para a mesma política nos estados relevantes e apresentaram maior retorno descontado que a política baseline. Os resultados também evidenciaram o compromisso entre reduzir intervenções preventivas, aumentar a utilização do equipamento e aceitar maior risco de falha.

Palavras-chave: Processo de Decisão de Markov. Q-Learning. Manutenção preditiva. C-MAPSS. Aprendizado por reforço.

1 INTRODUÇÃO

Decisões de manutenção em sistemas produtivos são sequenciais: manter o equipamento em operação gera produção imediata, mas pode elevar o risco de falha; interromper a operação para manutenção reduz esse risco, porém introduz custo e indisponibilidade. Essa estrutura é compatível com um Processo de Decisão de Markov, no qual o estado representa a condição do sistema, as ações representam alternativas de operação ou manutenção e a recompensa traduz o compromisso entre produtividade, custo e risco.

O principal obstáculo prático é a disponibilidade de dados públicos com evolução completa do desgaste até a falha. O C-MAPSS foi escolhido porque oferece trajetórias multivariadas run-to-failure. Neste projeto, entretanto, ele não é interpretado como uma linha de produção nem como fonte de decisões históricas de manutenção. O padrão de degradação observado nos sensores é utilizado como proxy para calibrar a dinâmica dos estados do MDP; ações, custos e efeitos de intervenção pertencem ao ambiente simulado construído neste trabalho.

O objetivo geral é desenvolver e avaliar uma política inteligente de manutenção capaz de decidir quando continuar operando e quando intervir, comparando uma política baseada em regras, uma solução por Value Iteration e uma política aprendida por Q-Learning.

2 BASE DE DADOS

Foram utilizados os quatro subconjuntos do Dataset nº 6 do repositório NASA PCoE: FD001, FD002, FD003 e FD004. Cada linha contém o identificador da unidade, o ciclo de operação, três configurações operacionais e 21 medições de sensores. No treinamento, cada trajetória progride até a falha. Nos dados de teste, a trajetória é interrompida antes da falha e um arquivo separado informa o RUL verdadeiro.

Conjunto	Registros de treino	Unidades no arquivo	Condições	Modos de falha
FD001	20.631	100	1	1
FD002	53.759	260	6	1
FD003	24.720	100	1	2
FD004	61.249	249	6	2

Tabela 1 – Características dos conjuntos utilizados. Fonte: elaboração própria a partir dos arquivos C-MAPSS.

Foi observada uma divergência no FD004: o arquivo README declara 248 trajetórias de treinamento e 249 de teste, enquanto os arquivos efetivamente fornecidos apresentam 249 IDs no treino, 248 IDs no teste e 248 valores RUL. Para preservar a reprodutibilidade, a análise utilizou os arquivos recebidos sem alterar registros e a divergência foi mantida documentada.

3 METODOLOGIA




Figura 1 – Fluxo metodológico do projeto. Fonte: elaboração própria.

3.1 Cálculo do RUL e pré-processamento

Para os dados de treinamento, a vida útil remanescente de cada observação foi calculada pela diferença entre o último ciclo da unidade e o ciclo corrente. O RUL foi usado para selecionar e validar variáveis durante a construção do indicador de saúde, mas não é fornecido como observação ao agente durante a tomada de decisão.

Nos conjuntos com múltiplas condições operacionais, as observações foram agrupadas em seis regimes com base nas três configurações operacionais e os sensores foram normalizados dentro de cada regime. Essa etapa reduz o risco de interpretar uma mudança de regime como degradação.

3.2 Seleção de sensores e Health Index

Sensores com variação desprezível foram descartados. Os dez sensores com maior associação monotônica absoluta com o RUL foram selecionados em cada conjunto. Em seguida, aplicou-se PCA e o primeiro componente foi orientado e normalizado para formar um Health Index entre zero e um, em que valores maiores representam melhor condição.




Figura 2 – Correlação entre Health Index e RUL. Fonte: resultados do projeto.

A correlação de Spearman entre HI e RUL foi 0,77 no FD001, 0,78 no FD002, 0,84 no FD003 e 0,77 no FD004. O comportamento consistente nos quatro conjuntos indica que o índice captura uma parcela relevante da evolução da degradação.

3.3 Estados, ações e transições

O HI foi discretizado em quatro estados: saudável, moderado, severo e crítico. Um quinto estado representa a falha. As probabilidades de transição durante a ação de operação normal foram estimadas contando as mudanças entre estados consecutivos nas trajetórias de treinamento. Pequenas reversões para estados mais saudáveis, atribuídas ao ruído de sensores, foram absorvidas no estado atual para manter a hipótese de dano progressivo.

Estado	Faixa do HI	Interpretação
Saudável	$HI > 0,75$	Baixa degradação
Moderado	$0,50 < HI \leq 0,75$	Degradação observável
Severo	$0,25 < HI \leq 0,50$	Desgaste elevado
Crítico	$HI \leq 0,25$	Próximo à falha
Falha	terminal	Reparo corretivo

Tabela 2 – Estados discretos do MDP. Fonte: elaboração própria.

Foram modeladas três ações: operar normalmente, operar com carga reduzida e executar manutenção preventiva. A manutenção retorna o equipamento ao estado

saudável. A carga reduzida conserva produção parcial e reduz pela metade, como hipótese do simulador, a probabilidade de transição para estados piores.

3.4 Função de recompensa e algoritmos

Os valores econômicos não pertencem ao dataset NASA. Foram definidos explicitamente para o cenário-base: +10 por ciclo de operação normal, +6 sob carga reduzida, -25 para manutenção preventiva e -100 para falha/reparo corretivo. O fator de desconto utilizado foi $\gamma = 0,95$. A baseline opera nos estados saudável e moderado e realiza manutenção a partir do estado severo.

A política ótima do MDP foi calculada por Value Iteration. Em paralelo, um agente Q-Learning foi treinado por interação com o mesmo ambiente, utilizando exploração epsilon-greedy e atualização incremental da função Q. A comparação entre os métodos verifica se o agente sem acesso direto à solução analítica consegue aprender a mesma decisão.

4 RESULTADOS

4.1 Política aprendida

Nos quatro conjuntos, Value Iteration produziu a mesma política: operar nos estados saudável, moderado e severo e realizar manutenção preventiva no estado crítico. O Q-Learning convergiu para a mesma decisão nos estados relevantes. A ação de carga reduzida não foi selecionada no cenário-base; com os custos definidos, a perda imediata de produção foi maior que a redução esperada do risco.

Estado	Baseline	Value Iteration	Q-Learning
Saudável	Operar	Operar	Operar
Moderado	Operar	Operar	Operar
Severo	Manutenção	Operar	Operar
Crítico	Manutenção	Manutenção	Manutenção

Tabela 3 – Comparação das políticas. Fonte: resultados do projeto.

4.2 Retorno descontado




Figura 3 – Retorno descontado das políticas. Fonte: resultados do projeto.

O retorno descontado a partir do estado saudável aumentou de 195,88 para 198,57 no FD001; de 193,51 para 197,52 no FD002; de 197,02 para 198,25 no FD003; e de 196,22 para 197,11 no FD004. Como Value Iteration e Q-Learning chegaram à mesma política, seus retornos coincidem no cenário avaliado.

4.3 Manutenção, falhas e disponibilidade




Figura 4 – Frequência de manutenção preventiva. Fonte: resultados do projeto.

A política otimizada reduziu a frequência de manutenção em todos os conjuntos. No FD001, por exemplo, a taxa caiu de 123,6 para 86,8 manutenções por 10 mil ciclos; no FD004, de 102,2 para 57,6. Essa redução aumenta a utilização do equipamento, mas também torna a política menos conservadora.

Nos FD003 e FD004 surgiu o principal trade-off do projeto. A baseline praticamente elimina falhas porque intervém já no estado severo. A política otimizada adia a manutenção até o estado crítico e, por isso, apresenta respectivamente 14,2 e 18,8 falhas por 10 mil ciclos na simulação. Mesmo assim, seu retorno descontado permanece superior, pois a função objetivo atribui valor à continuidade da operação. Esse resultado evidencia que a política depende diretamente dos custos e do nível de risco aceitável.

5 DISCUSSÃO

O uso do C-MAPSS deve ser interpretado como uma simplificação controlada. O conjunto fornece curvas completas de degradação, mas não registra decisões de manutenção de uma linha de produção. Assim, o projeto utiliza somente a estrutura temporal de deterioração para estimar estados e transições naturais. Os efeitos das

ações de manutenção e carga reduzida são hipóteses do ambiente e não devem ser atribuídos à NASA.

A concordância entre Value Iteration e Q-Learning é um resultado relevante: o primeiro método utiliza explicitamente o modelo do MDP, enquanto o segundo aprende pela experiência. A convergência para a mesma política indica que, no ambiente construído, o agente foi capaz de recuperar a decisão produzida pelo planejamento dinâmico.

A comparação com a baseline também mostra que não existe uma política universalmente superior sem especificar o critério econômico e de segurança. Quando falhas são penalizadas mais fortemente, uma política mais conservadora tende a se tornar atraente; quando a indisponibilidade e a manutenção têm maior peso, adiar a intervenção pode aumentar o retorno. Portanto, uma implantação industrial exigiria custos reais, limites de segurança e validação com dados do processo específico.

6 CONCLUSÃO

O projeto demonstrou uma aplicação completa de MDP e Aprendizado por Reforço ao gerenciamento de manutenção. As trajetórias C-MAPSS foram transformadas em um Health Index, estados discretos e probabilidades de transição; em seguida, políticas de decisão foram obtidas por Value Iteration e Q-Learning e comparadas com uma regra simples.

Nos quatro conjuntos avaliados, Value Iteration e Q-Learning convergiram para a política de operar até o estado severo e realizar manutenção no estado crítico, apresentando maior retorno descontado que a baseline. Ao mesmo tempo, FD003 e FD004 evidenciaram que adiar a intervenção aumenta a exposição a falhas. O resultado mais importante, portanto, não é apenas uma política específica, mas a demonstração de como dados de degradação podem ser incorporados a um modelo sequencial de decisão e como diferentes custos alteram o equilíbrio entre produtividade, manutenção e risco.

Como continuidade, recomenda-se realizar análise de sensibilidade sistemática dos custos, incorporar demanda e disponibilidade de equipes de manutenção ao estado

do MDP e, quando disponível, substituir as hipóteses de intervenção por dados industriais de manutenção.

REFERÊNCIAS

SAXENA, A.; GOEBEL, K.; SIMON, D.; EKLUND, N. Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation. Proceedings of the International Conference on Prognostics and Health Management, 2008.

NASA. Prognostics Center of Excellence Data Set Repository. Dataset nº 6: Turbofan Engine Degradation Simulation Data Set.

SUTTON, R. S.; BARTO, A. G. Reinforcement Learning: An Introduction. 2. ed. Cambridge: MIT Press, 2018.

PUTERMAN, M. L. Markov Decision Processes: Discrete Stochastic Dynamic Programming. Hoboken: Wiley, 1994.